

问题 1:

问题 1 第一小问

推导过程(涉及高斯分布, 贝叶斯公式, 分层贝叶斯)

该问中基于传统方法(譬如最小二乘)这些方法无法考虑观测值过程中的存在的一些观测噪声, 因此, 在这里我们引入贝叶斯推导框架, 将观测过程中存在的观测噪声考虑在内(指下文公式中的 E); 总的来说, 该问题可以转化为回归方程问题求解, 即存在观测方程为

$$Y = XG + E \quad (1)$$

其中, Y 为观测值, $Y = [y_1, y_2], Y \in R^{Tem \times 2}, y_i = [y_{i,1}, y_{i,2}, \dots, y_{i, Tem-1}, y_{i, Tem}]^T \in R^{Tem \times 1}$, G

是传递矩阵 (即是我们需要计算解答的), $G \in R^{2 \times 2}$, X 是权重输入自变量(即温度),

$X \in R^{Tem \times 2}$; E 是观测噪声 $E \in R^{Tem \times 2}$ 。

那么, 基于式(1), 可以进一步表示成

$$y_k = Xg_k + e_k \quad (2)$$

其中, $y_k \in R^{Tem \times 1}, X \in R^{Tem \times 2}, g_k \in R^{2 \times 1}, e_k \in R^{Tem \times 1}, \bullet_k$ 表示第 k 列向量。

我们知道, 传统的贝叶斯推导公式为:

$$P(A|B) = \frac{P(A, B)}{P(B)} \quad (3)$$

而在式 (2) 中, 我们要求解的为矩阵 g_k , 那么我们可以基于公式(2)构建关于矩阵 g_k 的后验概率密度, 即有

$$p(g_k | y_k, \theta) = \frac{p(y_k | g_k, \theta) p(g_k | \theta)}{p(y_k | \theta)} = \frac{p(y_k | g_k, \theta) p(g_k | \theta)}{\int p(y_k | g_k, \theta) p(g_k | \theta) dg} \quad (4)$$

其中, θ 表示超参数集合。

在这里, 我们假设 g_k 服从高斯分布, 那么有

$$g \sim N(0, \Sigma_g) \quad (5)$$

其中

$$\Sigma_g = \text{diag} \{ \alpha_1, \alpha_2, \dots, \alpha_M \} \quad (6)$$

那么关于 g_k 的先验概率密度函数服从

$$p(g | \Sigma_g) = \prod_{m=1}^M p(g_m | \alpha_m) = (2\pi)^{-\frac{M}{2}} |\Sigma_g|^{-\frac{1}{2}} e^{-\frac{1}{2} g^T \Sigma_g^{-1} g} \quad (7)$$

下面我们假设噪声 e_k 为高斯白噪声，那么有

$$e_k \sim N(0, \Sigma_v) \quad (8)$$

$$\Sigma_v = \sigma^2 I \quad (9)$$

所以，优于高斯分的性质我们可知

$$e_k = y_k - Xg_k \sim N(0, \Sigma_v) \quad (10)$$

那么既有

$$y_k \sim N(Xg_k, \Sigma_v) \quad (11)$$

关于观测值 y_k 的概率密度函数可以表示为

$$p(y_k) = (2\pi)^{-\frac{N}{2}} |\Sigma_v|^{-\frac{1}{2}} e^{-\frac{1}{2}(y_k - Xg_k)^T \Sigma_v^{-1} (y_k - Xg_k)} \quad (12)$$

那么，基于式(4)的 g_k 的后验概率密度可以表示为

$$p(g_k | y_k, \theta) = N(g_k | Cy_k, P) \quad (13)$$

其中

$$P = (X^T \Sigma_v^{-1} X + \Sigma_g^{-1})^{-1} \quad (14)$$

$$C = PX^T \Sigma_v^{-1} \quad (15)$$

公式求解过程(设计变分贝叶斯，EM 算法，KL 熵)

接下来，为了得到一个合适的值，并对公式中相应参数的值进行求解，我们在这里引入变分贝叶斯和 EM 算法来计算边际似然概率密度函数的大小，并使得边际似然概率密度函数达到最大。那么，结合 EM 算法，我们可以得到一个关于 y 边际似然的目标函数

$$Q(\theta, \hat{\theta}^{(k)}) = E_{p(g|y, \theta^{(k)})} [\ln p(y | g, \theta) + \ln p(g | \theta)] \quad (16)$$

并通过最大化该目标函数求得参数值

$$\hat{\theta}^{(k+1)} = \arg \max_{\theta} Q(\theta, \hat{\theta}^{(k)}) \quad (17)$$

目标函数可分为 A,B,C 三部分,即

$$Q(\theta, \hat{\theta}^{(k)}) = E_{p(g_k | y_k, \theta^{(k)})} \ln p(y_k | g_k, \theta) + E_{p(g_k | y_k, \theta^{(k)})} \ln p(g_k | \theta) \quad (18)$$

A
B

下面对 A,B 分别求积分，即有

A Section

$$E_{p(g_k | y_k, \theta^{(k)})} \ln p(y_k | g_k, \theta) = -\frac{1}{2} \{ N \ln 2\pi + \ln |\Sigma_v| + y_k^T \Sigma_v^{-1} y - 2y_k^T \Sigma_v^{-1} U C^{(k)} y_k + \text{trace} \{ (X^T \Sigma_v^{-1} X) P^{(k)} \} + y_k^T (C^{(k)})^T (X^T \Sigma_v^{-1} X) C^{(k)} y_k \} \quad (19)$$

B Section

$$E_{p(g_k|y_k, \theta^{(k)})} \ln p(g_k | \theta) = -\frac{1}{2} \left\{ M \ln 2\pi + \ln |\Sigma_g| + \text{trace} \left\{ \Sigma_g^{-1} P^{(k)} \right\} + y_k^T \left(C^{(k)} \right)^T \Sigma_g^{-1} C^{(k)} y_k \right\} \quad (20)$$

于是

$$\begin{aligned} Q(\theta, \hat{\theta}^{(k)}) = & -\frac{1}{2} \{ N \ln 2\pi + \ln |\Sigma_v| + y_k^T \Sigma_v^{-1} y_k - 2 y_k^T \Sigma_v^{-1} X C^{(k)} y_k + \text{trace} \{ (X^T \Sigma_v^{-1} X) P^{(k)} \} \\ & + y_k^T \left(C^{(k)} \right)^T (X^T \Sigma_v^{-1} X) C^{(k)} y_k + M \ln 2\pi + \ln |\Sigma_g| + \text{trace} \{ \Sigma_g^{-1} P^{(k)} \} + y_k^T \left(C^{(k)} \right)^T \Sigma_g^{-1} C^{(k)} y_k \} \end{aligned} \quad (21)$$

Section 3 Calculate σ^2

$$\begin{aligned} Q(\sigma^2, \hat{\theta}^{(k)}) = & -\frac{1}{2} \{ \ln |\Sigma_v| + y_k^T \Sigma_v^{-1} y_k - 2 y_k^T \Sigma_v^{-1} U C^{(k)} y_k \\ & + \text{trace} \{ (X^T \Sigma_v^{-1} X) P^{(k)} \} + y_k^T \left(C^{(k)} \right)^T (X^T \Sigma_v^{-1} X) C^{(k)} y_k \} \end{aligned} \quad (22)$$

$$\frac{dQ(\sigma^2, \hat{\theta}^{(k)})}{d\sigma^2} = 0 \quad (23)$$

$$(\sigma^2)^{(k+1)} = \frac{y_k^T y_k + \sum S(t, t) + y_k^T C^T X^T X C y_k - 2 y_k^T U C y_k}{N} \quad (24)$$

$$S^{old} = X P^{old} X^T \quad (25)$$

Section 4 Calculate Σ_g

$$Q(\alpha_m, \hat{\theta}^{(k)}) = -\frac{1}{2} \left\{ \ln |\Sigma_g| + \text{trace} \left\{ \Sigma_g^{-1} P^{(k)} \right\} + y_k^T \left(C^{(k)} \right)^T \Sigma_g^{-1} C^{(k)} y_k \right\} \quad (26)$$

$$\frac{dQ(\alpha_m, \hat{\theta}^{(k)})}{d\alpha_m} = 0 \quad (27)$$

$$\alpha_m = P^{(k)}(m, m) + \left(O^{(k)}(m) \right)^2 \quad (28)$$

Where

$$O^{(k)}(m) = C^{(k)} y_k \quad (29)$$

$$\Sigma_g = \text{diag} \{ \alpha_1^{(k+1)}, \alpha_2^{(k+1)}, \dots, \alpha_M^{(k+1)} \} \quad (30)$$

那么，基于以上总的来说，更新公式可以表述为如下

Input: θ^{ini}, y_k, X

and we can define that $\theta^{ini} = [\sigma_{ini}^2, \alpha_1, \alpha_2, \dots, \alpha_M]$.

in addition, y_k is the target value.

And U is the transform matrix (we can express X as 'regressors' in this system)

Output: g_k

Step1: repeat until $\frac{\|Q(\theta, \hat{\theta}^{(k+1)}) - Q(\theta, \hat{\theta}^{(k)})\|}{\|Q(\theta, \hat{\theta}^{(k)})\|} < \varepsilon, \varepsilon$ is any small number

Step1-1: Calculate σ^2 by (24)

Step1-2: Calculate α_m by (28) and update Σ_g by (30)

Step2: Compute $g_k = C^{(k)} y_k$

推导公式已经全部完成。(上面一字不改的要照抄，可以改一些语句通顺的地方，但是涉及公式和参数的地方千万不要改)

该方法的优点：

引入了贝叶斯框架，即相应参数的先验分布，这使得我们可以在一定程度上提高参数估计的准确率。同时，引入 EM 算法和变分贝叶斯，这使得我们的解为全局最优解，而不是局部最优；不仅如此，基于贝叶斯发展的回归方程求解模型，可以在一定程度上压制噪声，相对于传统方法，在参数估计上具有一定的性能提升。

第一题中问题要求我们探究乙醇转化率和 C4 烯烃选择性与温度的关系，已知附件一中共有 21 种不同的催化剂，那么便可以得到 21 个 A 矩阵，即构成了 21 个不同的回归方程(这里需要手动替换 Y 和 X 中的数据)。通过该方程，来说明乙醇转化率和 C4 烯烃选择性与温度的关系。在这里，公式(1)构成了一个通用的回归方程矩阵。其中不同的是传递矩阵 A 的变化来说明不同催化剂下温度和其他指标的关系。

(结果展示，有 21 个催化剂，那么可以得到 21 个矩阵 A 构建的 21 个回归方程，我们可以将这 21 个方程列出来。建议论文中只列出一个，剩下 20 个放进附录)

运行 Optimized_Question_1_1.m 文件

另一个.m 文件千万不要动